

멀티모달 기반 영업 상담·마케팅 AI 에이전트

Technical Report: 지능형 폐쇄망 완결형 아키텍처 및 구현 명세

Document Version: 1.0

Date: 2026-06-08

Document Type: Technical Report

Audience: Internal Stakeholders & AI Engineers

Abstract. 본 보고서는 한화손해보험의 전사 영업 데이터와 고능률 상담사의 성공 콜 노하우를 통합하여, 상담사에게는 즉시 활용 가능한 맞춤 스크립트를, 마케팅 담당자에게는 AI 기반 대상 리스트를 제공하는 폐쇄망 완결형 AI Agent 시스템의 설계 및 구현 명세를 다룹니다.

Executive Summary

본 시스템은 분산된 전사 영업 데이터를 통합하고, 멀티모달(정형/비정형 문서/음성) AI 에이전트를 활용하여 현장의 실질적인 생산성을 제고하는 것을 목표로 합니다. 기존 운영 중인 ML 상품추천 배치를 파괴하거나 대체하지 않으며, 해당 추천 결과를 에이전트의 입력으로 계승하여 상담사가 실제로 활용 가능한 언어(가이드)로 변환하는 레이어로 기능합니다.

4 Layers

시스템 아키텍처 계층

8 Nodes

상담사 지원 워크플로우

2 Stages

STT 직후 PII 마스킹

40GB GPU

인터넷 차단 폐쇄망 인프라

Contents

- 배경 및 문제 정의
- 시스템 개요
- 데이터 소스 및 처리 흐름
- AI Agent 핵심 기술
- 사용자 시나리오 (상담사/마케팅)
- 개인정보 보호 및 폐쇄망 배포
- 기술 스택
- 비즈니스 임팩트
- 데모와 향후 확장
- 한계 및 운영 원칙

1. 배경 및 문제 정의

기존 ML 추천 모델은 '무엇(What)'을 권해야 할지는 알려주지만, '어떻게(How)' 설득해야 할지에 대한 맥락적 가이드를 제공하지 못합니다.

분산된 고객 데이터와 비정형 데이터(녹취록 등)가 개별적으로 존재하여, 현장 상담사는 데이터를 취합하고 상담 전략을 수립하는 데 과도한 시간을 소모하고 있습니다. 마케팅 담당자 또한 타겟 리스트를 추출하기 위해 IT 부서의 SQL 작성 지원에 의존해야 하는 병목이 존재합니다. 이를 해결하기 위해, 성공 사례 노하우를 내재화한 통합 AI 에이전트 도입이 필수적입니다.

2. 시스템 개요

시스템은 데이터의 수집부터 사용자 서비스에 이르는 4계층(4-Tier) 아키텍처로 설계되었습니다.

본 아키텍처는 기존 시스템 인프라를 침해하지 않고 병렬로 작동하며, 정보 보안과 고속 검색을 위해 인프로세스 DB(DuckDB)와 벡터 DB(Chroma)를 통합 운영합니다.

Layer 4: 사용자 서비스 (User Service)

상담사 스크립트 대시보드 / 마케팅 대화형 타겟 추출 UI (Radio 기반)



Layer 3: AI Agent (LangGraph / LLM)

8노드 워크플로우 라우팅 / HyDE 검색 / Dynamic Few-Shot 프롬프팅



Layer 2: 데이터 저장소 (Data Storage)

분석 DB (DuckDB - OLAP) / 벡터 검색 DB (Chroma - 비정형 임베딩)



Layer 1: 데이터 소스 (Data Sources)

정형 데이터(Oracle DB), 기존 ML 추천 결과, 콜센터 음성(WAV), 교육 문서

Figure 1. 시스템 4계층 아키텍처 다이어그램

3. 데이터 소스 및 처리 흐름

본 시스템은 동일한 데이터 자산을 활용하되, **상담사 지원 경로와 마케팅 대상 추출 경로를 목적별로 분리해 제공합니다.**

핵심 설계 원칙은 단순합니다. 정형 데이터는 재현 가능한 분석 질의를 위해 DuckDB에, 음성·문서 기반 비정형 데이터는 검색 증강 생성을 위해 Chroma에 적재합니다. 이때 기존 운영계의 ML 상품추천 결과는 별도의 예측 시스템으로 다시 만들지 않고, 현재 운영 중인 결과를 **입력 신호로 계승**하여 상담 스크립트 생성의 맥락 정보로 사용합니다.

데이터 영역	원본 형태	주 사용 경로	처리 및 반영 방식
고객 기본정보	정형 RDB	상담사 / 마케팅 공통	인구통계, 유입채널, 기본 속성을 주기 동기화하여 분석 테이블로 반영
계약·담보 / 통화·마케팅 이력	정형 RDB	상담사 / 마케팅 공통	보장 현황 조회, 고객 유형 판별, 필터 조건 검증용으로 DuckDB 적재
기존 ML 상품추천 결과	정형 RDB / 배치 산출물	상담사 중심	기존 추천 결과를 파일·테이블·조회 API 등 현재 운영 방식에 맞춰 수신하고, 에이전트 입력값으로 승계
콜센터 녹취	음성 WAV	상담사 중심	STT → 2단계 비식별화 → 청킹·임베딩 후 성공 콜 검색 자산으로 적재
상품 교육 자료	PDF / DOCX / PPTX	상담사 중심	문서 파싱, 마크다운 변환, 청킹 및 임베딩을 거쳐 상품 근거 문서로 저장

Table 1. 데이터 소스, 서비스 경로, 반영 방식 요약




Figure 2. 상담사 지원과 마케팅 추출을 분리한 데이터 제공 흐름

Data Reflection Pattern

- 정형 데이터: 운영 DB → 주기 동기화 배치 → DuckDB 분석 테이블
- 기존 ML 결과: 운영계 산출물 → 조회/파일/API 수신 → 상담사 에이전트 입력

Figure 3. 즉시 반영 가능한 데이터 연계 패턴 요약

4. AI Agent 핵심 기술

AI Agent 계층의 핵심은 **상담사 지원은 그래프 기반 제어형 워크플로우로, 마케팅 추출은 조건 기반 실행형 흐름으로 분리했다는 점**입니다.

상담사 지원은 설명 가능성과 재현 가능성이 중요하므로 LangGraph 기반 8노드 파이프라인으로 구성했습니다. 반면 마케팅 대상 추출은 자유 질의형 SQL 생성보다 오류 통제가 중요하므로, 대화형 폼으로 수집한 조건을 검증된 쿼리 템플릿에 매핑하는 방식을 채택했습니다. 즉, 두 기능 모두 AI를 사용하지만 **자율성이 필요한 구간과 결정론이 필요한 구간을 명확히 구분**합니다.




Figure 4. 상담사 지원 에이전트의 8노드 실행 구조

상담 스크립트 생성에는 **CoT 2단계 체인**을 적용합니다. 1단계에서는 고객 상태, 담보 공백, 과거 통화 맥락을 요약해 접근 각도를 도출하고, 2단계에서는 HyDE 기반 검색과 Dynamic Few-Shot 예시를 결합해 실제 상담에 가까운 문장을 생성합니다. 이 구조는 단순히 상품명을 나열하는 대신, 왜 이 고객에게 이 접근이 적절한지를 먼저 해석한 뒤 언어화한다는 점에서 현업 활용성이 높습니다.




Figure 5. 기존 ML 추천 결과를 상담 언어로 전환하는 Agent 레이어

Agent Design Principle

- 상담사 지원: LLM + RAG + 그래프 제어 + 스트리밍 출력
- 마케팅 추출: 조건 입력 + 검증된 템플릿 질의 + 결과 다운로드

- 공통 원칙: AI 호출 최소화, 풀백 가능, 결과 근거 노출, 폐쇄망 구동

Figure 6. 서비스별 AI 사용 원칙 비교

5. 사용자 시나리오 (상담사/마케팅)

본 장에서는 같은 플랫폼 위에서 동작하지만 목적과 출력이 다른 두 개의 서비스 경로, 즉 **상담사 지원 흐름**과 **마케팅 대상 추출 흐름**을 분리하여 설명합니다.

5.1 상담사 지원 흐름

상담사 시나리오의 시작점은 고객번호 입력입니다. 시스템은 고객을 신규·미연결·이력 고객으로 자동 분류한 뒤, 계약 및 보장 현황, 기존 운영계 추천 결과, 과거 통화 맥락, 상품 근거 문서를 결합해 상담 직전에 바로 사용할 수 있는 결과를 생성합니다. 출력은 단순 요약이 아니라 **스크립트 + 근거 + 접근 키워드**의 형태로 제공됩니다.




Figure 7. 상담사 지원의 실제 실행 흐름

Mockup A · 상담사 화면: 고객 분석 + 스크립트 + 해시태그

[고객 분석 완료]

- 고객 유형: 이력 고객
- 핵심 포인트: 실손 보유 / 3대 질병 진단비 공백 / 최근 통화 이력 존재
- 운영계 추천 결과: 건강보험 추천 신호 존재

[생성 스크립트 예시]

"고객님, 현재 실손은 잘 유지 중이시지만 중증 질환 진단비 쪽은 상대적으로 공백이 있습니다. 최근 의료비 부담 구조를 보면 치료비보다 진단 시점의 자금 준비가 중요해지는 경우가 많아서, 현재 보장 구조를 기준으로 보완 방향만 간단히 설명드려도 괜찮으실까요?"

[접근 키워드]

#과거통화맥락직접한기 #담보Gap우선설명 #설명형설득톤

Figure 8. 상담사 출력물 예시: 고객 현황, 스크립트, 접근 키워드

Mockup B · 성공 콜 검색 및 근거 카드

[근거 검색 결과]

- 검색 방식: HyDE 기반 가상 우수 응답 생성 후 유사 콜 검색
- 선택 근거: 고객 유형 유사 / 담보 공백 유사 / 성사된 실제 상담 어투 반영

[우수 콜 인용 요약]

- 실손 유지 고객에게 추가 보장 공백을 먼저 설명
- 상품명보다 보장 구조의 부족분을 먼저 언급
- 설명형 접근이 재통화 수용률 측면에서 유리

[활용 방식]

- 성공 콜 예시를 **Dynamic Few-Shot**으로 주입
- 교육자료 문단을 근거 문서로 병렬 참조

Figure 9. 상담 스크립트 생성에 사용되는 검색 근거 예시

5.2 마케팅 대상 추출 흐름

마케팅 흐름은 자유로운 자연어 질의보다 조건 수집과 결과 검증을 우선합니다. 담당자는 4단계 폼을 통해 상품, 채널, 신규 여부, 목표 인원, 전략을 설정하고, 시스템은 이를 검증된 질의 템플릿에 매핑해 대상 리스트를 산출합니다. 이때 화면에 제시되는 체결율 정보는 예측치가 아니라 **과거 유사 마케팅 실적 참고치**입니다.




Figure 10. 마케팅 대상 추출의 실제 실행 흐름

Mockup C · 마케팅 담당자 화면: 조건 입력 + 결과 다운로드

[입력 예시]

- 상품군: 건강보험
- 채널: TM
- 대상군: 40대 / 기존 고객
- 목표 인원: 3,000명
- 전략: 과거 실적 기반 우선

[출력 예시]

- 직전 유사 캠페인 실제 체결율 참고 카드 표시
- 조건 검증 후 대상 리스트 생성
- Excel 다운로드 후속 업무 연결

* UI에는 'ML 예측 아님, 과거 실적 참고치' 문구를 명시하여 사용 해석의 혼선을 방지합니다.

Current Demo Scope

- 상담사 데모: 이력 고객 시나리오를 기준으로 접근 각도 분석, 성공 콜 검색, 스크립트 생성, 해시태그 출력
- 마케팅 데모: 건강보험/TM/40대/3,000명 조건 기반으로 대상 추출 및 Excel 다운로드

Figure 12. 현재 구현 및 데모 가능한 사용자 흐름 범위

6. 개인정보 보호 및 폐쇄망 배포

보안 설계의 핵심은 원문 최소 보유, 완전 폐쇄망 구동, 외부 의존성 제거의 세 가지 원칙입니다.

시스템은 인터넷이 차단된 내부망 단일 서버에서 동작하며, 음성·문서·정형 데이터를 모두 로컬에서 처리합니다. 특히 녹취 데이터는 STT 직후 곧바로 비식별화되며, 마스킹이 완료된 텍스트와 임베딩만 저장됩니다. 이는 기술 성능보다 우선하는 운영 제약이며, 모든 구성 요소는 이 제약을 만족하는 범위에서 선택되었습니다.

[Original STT]

안녕하세요, 제 이름은 홍길동이고 전화번호는 010-1234-5678입니다. 강남구 도곡동에 살고 있어요.

[Step 1 · 규칙 기반 마스킹]

안녕하세요, 제 이름은 홍길동이고 전화번호는 [PHONE_NUM]입니다. 강남구 도곡동에 살고 있어요.

[Step 2 · LLM 기반 비정형 PII 마스킹]

안녕하세요, 제 이름은 [NAME_1]이고 전화번호는 [PHONE_NUM]입니다. [LOCATION_1]에 살고 있어요.

Figure 13. STT 직후 수행되는 2단계 비식별화 파이프라인 예시

외부망

인터넷 및 외부 API 호출 차단 / 공개 SaaS 의존성 제거

내부 서비스망

Ubuntu / CUDA 12.4 / GPU 40GB 단일 서버에서 LLM, STT, DB, UI 일괄 구동

반입 절차

패키지 번들링(tar.gz) · 모델 가중치 분할 반입 · 사전 검증 후 오프라인 설치

Figure 14. 폐쇄망 배포 아키텍처와 반입 절차 요약




Figure 15. 즉시 반영 가능한 현실적 연계 방식: 운영계 결과 계승 후 화면 주입

7. 기술 스택

모든 구성 요소는 외부 인터넷 연결 없이 로컬 환경에서 구동 가능한 오픈소스 및 온프레미스 기술로 구성되었습니다.

구분	적용 기술	선택 사유
LLM / 서빙	Qwen2.5-27B / Ollama	한국어 지시 이행 능력이 우수하며 40GB VRAM 내 구동 최적화
STT	faster-whisper large-v3	높은 음성 인식률 및 로컬 추론 속도 보장
분석 DB	DuckDB	별도 데몬 없는 인프로세스 OLAP 엔진으로 폐쇄망 설치 용이
벡터 DB	Chroma	경량화된 임베딩 관리 및 RAG 검색 최적화
오케스트레이션	LangGraph	복잡한 에이전트 워크플로우의 순환 구조 및 상태 관리 용이


Table 2. 핵심 기술 스택 명세

8. 비즈니스 임팩트

AI 에이전트 도입은 영업 채널의 데이터 해석 비용을 낮추고, 마케팅 부서의 IT 의존도를 해소합니다.

구분	As-Is (도입 전)	To-Be (도입 후)
상담 준비	상담사가 여러 시스템에서 고객 정보를 수동 취합	AI가 정보를 자동 분석하여 맞춤 스크립트 즉시 제공
노하우 전파	신입 상담사는 개인의 경험에 의존 (편차 큼)	고능률 상담사의 성공 콜 어투 및 전략 자동 주입
타겟 추출	마케팅 담당자가 IT 부서에 SQL 작성 요청 (수일 소요)	자연어 기반 대화형 UI를 통해 담당자가 직접 즉시 추출

Table 3. 비즈니스 업무 흐름 변화 (As-Is vs To-Be)



9. 데모와 향후 확장

현재 데모 시스템은 고객 이력 기반 상담 준비와 마케팅 대상 추출 시나리오를 지원하며, 향후 레거시 연동을 강화할 계획입니다.

향후 확장 로드맵:

- 담보 상세 자유 질의:** 정해진 스크립트 외에 상담 중 발생하는 돌발 질문에 대한 실시간 문서 기반 QA 지원.
- 실시간 녹취 인덱싱:** 배치성 처리가 아닌, 콜 종료 직후 STT 변환 및 벡터 적재를 통한 실시간 피드백 루프 완성.
- 마케팅 배정 원스톱 연동:** 추출된 타겟 리스트를 즉시 영업 조직에 분배하는 레거시 시스템 다이렉트 연동.
- 신입 트레이닝 롤플레이:** AI 에이전트가 고객 역할을 수행하는 양방향 모의 상담 훈련 모듈 추가.

Roadmap Timeline

Phase 1	상담 스크립트 자동화	[완료/데모]
Phase 2	마케팅 대상 추출 셀프서비스	[완료/데모]
Phase 3	실시간 녹취 인덱싱	[확장]
Phase 4	레거시 직접 연동/배정 자동화	[확장]
Phase 5	신입 롤플레이·교육 모듈	[확장]

Figure 16. 기능 확장 로드맵 텍스트 타임라인

10. 한계 및 운영 원칙

본 시스템은 현실적인 연계 가능성과 통제 가능한 운영을 우선하며, 기존 업무 체계를 대체하기보다 **즉시 불일 수 있는 형태로 확장하는 것**을 기본 원칙으로 합니다.

10.1 현재 구현 상태

- **구현 완료 범위:** 정형 데이터 통합, 녹취 STT 및 비식별화, 교육자료 벡터화, 상담사 지원용 8노드 워크플로우, 마케팅 대상 추출 UI
- **데모 가능 범위:** 이력 고객 상담 스크립트 생성 시나리오와 건강보험/TM 기반 마케팅 대상 추출 시나리오
- **출력 형태:** 상담사 측은 스크립트·해시태그·근거 카드, 마케팅 측은 참고 체결율·대상 리스트·Excel 다운로드

10.2 즉시 반영 가능한 연계 방식

- **기존 ML 결과 계승:** 운영 중인 상품추천 배치 결과를 파일, 테이블, 조회 API 등 현재 방식 그대로 수신하여 에이전트 입력값으로 사용
- **정형 데이터 동기화:** Oracle 등 운영 DB의 고객/계약/이력 데이터를 주기 배치로 DuckDB에 반영
- **상담 화면 연계:** 웹 API를 통해 기존 상담사 화면의 상품추천 영역 또는 보조 패널에 AI 스크립트를 주입하는 방식으로 단기 적용 가능
- **마케팅 후속 처리:** 초기에는 Excel 다운로드 기반으로 업무를 연결하고, 이후 승인된 범위에서 직접 배정 연계로 확장

10.3 현실적 제약과 운영 원칙

- **추천 모델의 독립성:** 본 시스템은 기존 ML 상품추천 알고리즘을 대체하지 않으며, 그 결과를 해석 가능한 상담 언어로 전환하는 레이어입니다.
- **마케팅 지표의 투명성:** 화면에 제시되는 성과 수치는 ML 예측치가 아니라 **과거 유사 마케팅의 실제 체결율 참고치**임을 명시해야 합니다.
- **폐쇄망 제약:** 인터넷 차단, 단일 서버, 번들 설치라는 조건을 전제로 하므로 모델 크기·호출 횟수·의존성 관리가 엄격하게 제한됩니다.
- **환각 통제:** 상품·담보·혜택 관련 표현은 RAG 근거와 정형 데이터 범위 안에서만 생성되도록 가드레일을 유지합니다.
- **개인정보 최소 보유:** 비식별화 이전 원문을 저장하지 않고, 마스킹 완료 텍스트와 검색용 자산만 보존합니다.

11. 결론

본 멀티모달 기반 AI 에이전트는 분산된 데이터와 비정형 노하우를 단일 파이프라인으로 융합하는 강력한 도구입니다. 철저한 폐쇄망 요건과 비식별화 처리를 준수하면서도, 고도의 LangGraph 제어와 로컬 LLM 생태계를 결합하여 영업 현장의 실질적인 시간 단축과 품질 향상을 이끌어 낼 수 있습니다.

Appendix. 용어 및 구성요소 요약표

용어 / 기술명	설명
----------	----

LangGraph	노드와 엣지 기반의 그래프 구조로 LLM 에이전트의 복잡한 실행 흐름을 제어하는 프레임워크
HyDE	Hypothetical Document Embeddings. 질문에 대한 가상의 답변을 먼저 생성하여 검색 정확도를 높이는 기법
Dynamic Few-Shot	입력된 상황(고객 유형 등)과 가장 유사한 과거 성공 사례를 동적으로 검색하여 프롬프트 예시로 주입하는 방식
DuckDB	서버 데몬 없이 프로그램 내부에서 직접 실행(In-Process)되는 고성능 분석용 RDB (OLAP 최적화)
PII 마스킹	Personal Identifiable Information 마스킹. 개인정보를 식별할 수 없도록 다른 문자열로 치환하는 기술

* 참고: 본 문서는 한화손해보험 경진대회용 원본 기술보고서의 사실관계와 핵심 메시지를 유지하며, 가독성과 구조적 완결성을 높이기 위해 재구성(Redesign)된 문서입니다.